PHYSICAL AI / APPLIED COURSE 1 / FINAL PROJECT

AI-driven Autonomous Kitting System

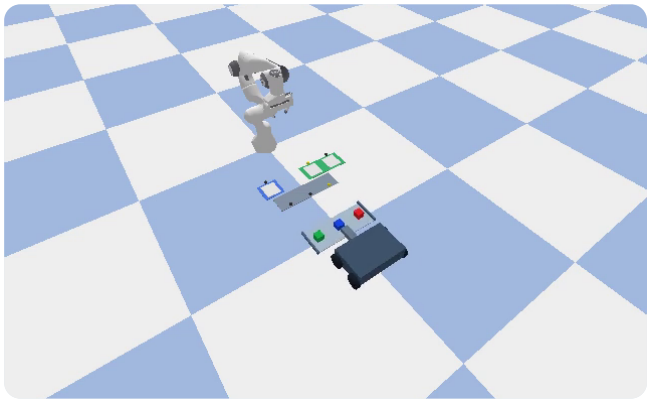
作業指示を変えるだけで、ロボットのキッティングを切り替える

QR × Qwen Task Planning × Independent Validator × PyBullet / Franka Panda

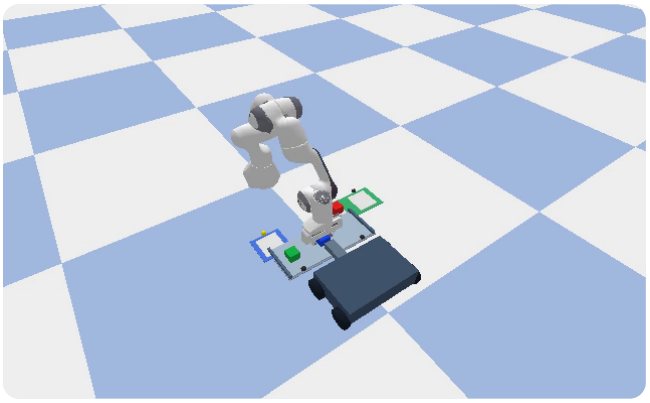
PROJECT CONCEPT

多品種少量生産における部品供給は、品種変更のたびに作業手順が変わる。本作品では**「指示の理解」と「ロボット制御」を分離**し、自然言語のSOPに対応した作業計画をQwenが生成。独立したValidatorが検証し、同一の制御プログラムでFranka Pandaが異なる仕分けを実行する。

QR画像 WO-ID取得 › **SOP 手順書取得** › **Qwen 計画生成** › **Validator 実行前検証** › **Panda Pick & Place**



実際のPyBullet映像：AGV模擬搬送・ドッキング



実際のPyBullet映像：Pandaによる連続仕分け

A / B
2種類の手順書から切替

3 / 3
各製品・各1試行の工程成功

1.20 mm
既配置部品の最大変位（約）

実測出典：Google Colab / PyBullet、2026-10-29実行記録 **run_20261029T124105Z**。本稿の「成功」は指定した定型SOPと既知座標における各1試行を指す。動画・JSONは実行時の記録を使用。

何をAIに任せ、何を制御プログラムに任せたか

LLMに関節角・軌道を直接生成させず、**自然言語から作業仕様を抽出する部分**に限定。誤推定が物理動作へ直結しないよう、複数の検証段階を設けた。

01｜QR・作業手順書

QR画像（`WO-2026-A/B`）をOpenCVでデコードし、対応するSOP-001/002をローカル辞書から取得。QRは作業指示IDのみを保持する。

02｜Qwen2.5-0.5B-Instruct

SOPの3工程を1行ずつ解釈し、**色＋配置先**をJSONとして出力。Colab CPUにモデルを読み込み、外部推論APIは使用しない。

03｜独立したPython Validator

JSON形式、許容値、SOP原文との一致をチェック。さらに部品欠品、配置先の占有をロボット動作前に検出して停止。

04｜AGV模擬搬送・Panda制御

低床台車が既知の部品供給座標まで運ぶ様子を運動学的に再現。PandaはIK・関節位置制御で把持→持上げ→運搬→配置→垂直退避を実行。

PRODUCT CHANGEOVER

製品A

WO-2026-A

3工程成功

```
red → A1
blue → B1
green → A2
```

製品B

WO-2026-B

3工程成功

```
red → A1
blue → A2
green → B1
```

実証した柔軟性

同じロボット制御ロジックで、SOPによって青・緑の**配置先**を変更できた。ここでは色ごとの部品は各1個であり、複数個の同色部品やBOM数量変更は未実装。

検証範囲を限定｜QRはColab上のPNG画像を読んでいる（仮想カメラではない）。AGV荷台は視覚用で、車輪駆動・荷重支持・SLAM・障害物回避を実装していない。部品座標と配置先は既知で、VLM物体認識・VLA学習は使用していない。

実測結果：品種切替と安全ゲート

各製品を新しいPyBulletシーンで初期化し、QR読取、Qwen再推論、Preflight、AGV模擬搬送、ロボット3工程、実行ログ・MP4保存まで実行した。結果は**各製品1試行**の記録。

3 / 3
Product A 工程成功

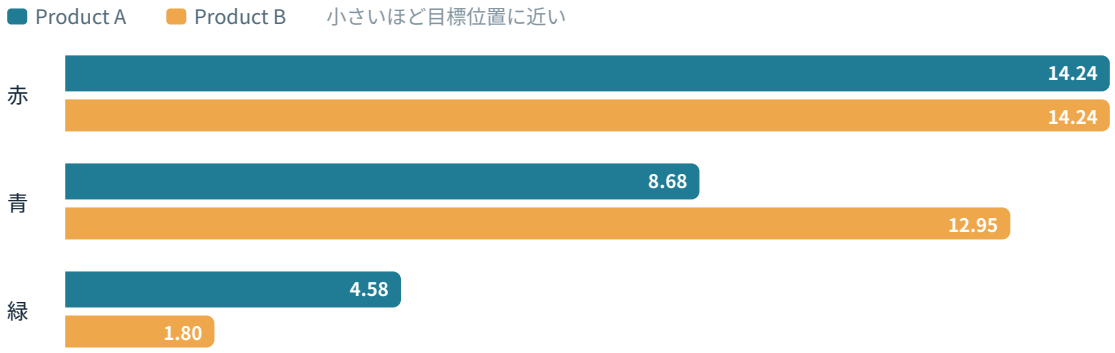
3 / 3
Product B 工程成功

2 / 2
欠品・占有テスト 各製品でPASS

製品別の配置誤差（目標区画中心とのXY距離、mm）

部品	A 配置先	A 誤差	B 配置先	B 誤差
赤	A1	14.24	A1	14.24
青	B1	8.68	A2	12.95
緑	A2	4.58	B1	1.80
平均	—	**9.17**	—	**9.66**

PLACEMENT ERROR / MM



配置済み部品の位置保持

後続工程後の既配置部品の最大変位はA **1.20 mm**、B **1.20 mm**。配置後の垂直退避を加え、以前の衝突による変位を抑制した。

LLMの推論時間

Qwenによる3工程の計画生成はA **16.65秒**、B **19.22秒**。Colab CPUでの計測であり、モデル初期ロード時間を含めない。

Fail-safeの検証（両製品で各1回）

STOP 赤部品を供給位置から移動させた欠品テスト：「Missing part at source: red」を検出。

STOP A1に先に緑部品を置いた占有テスト：「Occupied slot: A1」を検出。

検出時、ロボット関節状態は変化せず、テスト後にシミュレーションを復元。これは定義した2種類の異常に関する事前停止の確認であり、実機の安全規格適合を示すものではない。

実測値・推論の生出力・15個の工程イベントは `manifest_PRODUCT_A/B.json` に記録。動画はAGV 22フレーム、ロボット149フレーム、いずれも8fps。ロボット動画の`video_time_s`は録画内時刻。

学び：LLMを信じ切らず、工程全体を設計する

学び1｜LLMの役割を絞る

低レベル制御は既存のIK・軌道制御が担当し、LLMは自然言語の作業解釈に集中。既知座標の反復工程では、VLAを新たに学習させずに品種切替の価値を試験できた。

学び2｜独立した実行許可が必要

Qwenの出力はJSONコードフェンスを含む場合がある。形式・許容値・SOP整合をPythonで検査し、欠品と占有はロボットを動かす前に拒否した。

学び3｜後続工程で成果を壊さない

初期の実験では次工程への移動中に既配置部品を押してしまった。配置後に高い位置まで垂直退避する経路を導入し、今回の各試行では最大変位約1.20mmを確認した。

学び4｜モデル選定は業務単位で

別の探索的12問では、Qwen 6/12、Sarashina 8/12の完全一致。明確な指示と曖昧な指示で傾向が異なり、総合ベンチマークだけでは運用適合性を判断できない。

解釈上の注意｜Qwen対Sarashinaは小規模・プロンプト調整後の探索的比較で、一般性能の優劣を証明しない。ロボット制御と統合して実行したLLMはQwenのみ。ソブリンAIの推論基盤・データ所在・管理権限は本制作で検証していない。

実用化までの残課題

複数個の同色部品／BOM変更、実際のカメラによるQR・部品認識、実機の荷台・力学・ドッキング誤差、非常停止と機能安全、実運用における再試行・例外復旧、MES/WMS連携、長期間の統計的な成功率評価は未実装・未評価である。

再現性と提出物

PUBLIC GITHUB PACKAGE

Notebook：Colabで上からA/Bを連続実行できる構成。**README**：実行環境と制約。**実行記録**：製品A/Bのmanifest、QR画像、AGV・Robot MP4、ダッシュボード索引を同梱。

記録環境：Python 3.13.18／PyBullet 3.2.7／NumPy 2.1.3／PyTorch 2.11.0+cpu／Transformers 4.57.6。Google Colabクラウドで Qwenをロードして CPU推論。実験日時UTC 2026-10-29 12:41〜12:44、Run ID `run_20261029T124105Z`。

CONCLUSION

生産指示の変更を、ロボット制御コードの個別改修ではなく作業計画の変更で吸収できる可能性を、限定されたシミュレーション環境で実証した。今後は認識・搬送・安全性を段階的に検証し、部品供給工程の柔軟性向上につなげる。

参照：東京大学Physical AI応用1講座「最終課題（10/19改訂版）」／実行Notebookと保存済みmanifest（2026-10-29）。本PDFに個人情報は含めていない。正式提出時は所定のPDFファイル名で保存し、GitHub・YouTubeのURLとともにOmniCampusへ提出する。

APPENDIX / EXPLORATORY MODEL EVALUATION

製造作業指示におけるLLMの判断特性 Qwen vs Sarashina

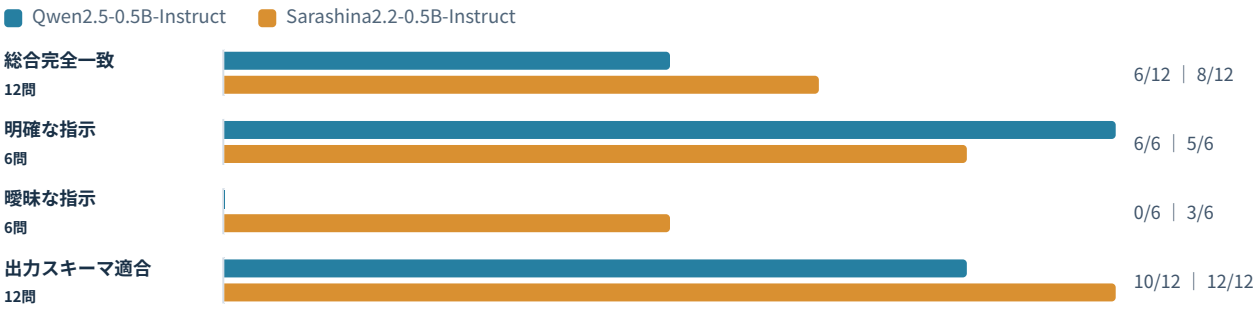
同じ日本語指示でもモデルによって得意・不得意が異なる。企業は「モデル単体の総合点」ではなく、**業務適合性とシステム全体の安全性**で選ぶ必要がある。

QWEN / 総合完全一致
6 / 12
50.0%｜明確な指示に強み

SARASHINA / 総合完全一致
8 / 12
66.7%｜曖昧指示で相対優位

PYTHON GATE / 誤実行許可
0 / 6
各モデルとも曖昧指示6問で0件

比較結果｜Prompt v2での追加12問（各モデル同じ指示）



「完全一致」は実行可否・部品色・配置先の3項目すべてが正解の場合。スキーマ適合にはJSON構文に加え許容値の遵守も含める。

Qwen｜明確な指示に強い

「青い部品をA2に置く」のように必要情報が揃う指示で**6/6正解**。一方、曖昧な指示では存在しない部品色や配置先を補うなど、完全一致は**0/6**だった。

Sarashina｜曖昧さへの対応で優位

総合**8/12**でQwenを上回った。曖昧指示の完全一致は**3/6**。ただし正常な指示を拒否する誤判定が**1件**あり、どの場面でも優れているわけではない。

LLMの推論結果 ≠ 実行許可｜Pythonによる独立ゲート

原文にない色・配置先の補完や許容外の値を検出して拒否。今回の各モデルの曖昧指示6件では**不適切な実行許可0件**。ただし、未知の表現や実機安全規格への適合を保証する結果ではない。

プロンプト改善の効果：先行4問ではSarashinaがv1の0/4からv2の3/4へ改善、Qwenは1/4から1/4。Few-shot例の追加とルール明確化を同時に行ったため、改善要因は分離できない。

解釈上の注意：12問・各1回の探索的評価で統計的な優劣は確定できない。先行4問と似た表現も含む。Prompt v2はSarashinaの失敗を観察後に調整したため、完全な事前固定ブラインド比較ではない。今回Sarashinaをロボット実行には接続していない。「国産モデルの可能性」は示唆されるが、データ所在・運用主体等のソブリン性は未検証。

示唆｜製造業では「明確指示の実行精度」「曖昧指示の確認精度」「構造化出力」「安全ゲート」を分けて評価する。

出典：本制作のColab実験 Step 12C / 13A–13D（2026-10-25）。比較対象 Qwen/Qwen2.5-0.5B-Instruct、sbintuitions/sarashina2.2-0.5b-instruct-v0.1。Colab CPU推論、do_sample=False、Prompt v2を共通使用。